

附录：零基础数学速查（对应西瓜书附录）

不求推导，只求看见公式不慌。机器学习里反复出现的就这三类：线性代数、求最小值、概率。

A. 矩阵与向量

写法	在说什么
向量 $\boldsymbol{x} = (x_1, \dots, x_d)^\top$	一个样本的 d 个特征排成一列
矩阵 $X \in \mathbb{R}^{m \times d}$	m 个样本、每个 d 维，一张数据表
内积 $\boldsymbol{w}^\top \boldsymbol{x} = \sum_j w_j x_j$	加权求和，线性模型的核心
矩阵乘 $W\boldsymbol{x}$	一次线性变换；神经网络一层（激活前）就是这个
$\ \boldsymbol{w}\ _2 = \sqrt{\sum w_j^2}$	欧氏长度；SVM 间隔、L2 正则都用它
$\ \boldsymbol{w}\ _1 = \sum w_j $	各分量绝对值之和；L1 正则用它
逆矩阵 A^{-1}	线性方程组的「除法」；不是每个矩阵都可逆
特征值 / 特征向量	矩阵只拉伸、不转向的方向；PCA 用协方差矩阵的特征向量
SVD	把矩阵拆成「旋转-缩放-旋转」；降维、推荐常用

梯度（对向量求导）：把「每个参数往哪边调、函数会变大」排成一个向量。记作 $\nabla_{\boldsymbol{w}} E$ 。机器学习几乎总是沿着 $-\nabla E$ 走。

B. 优化

机器学习 = 定义损失 $E(\theta)$ ，找让 E 小的参数 θ 。

梯度下降：

$$\theta \leftarrow \theta - \eta \nabla_{\theta} E$$

- η ：学习率。太大震荡甚至发散，太小学得极慢。
- 每次用全部样本的平均梯度叫批量；每次用一小撮叫 mini-batch（深度学习默认）。

拉格朗日乘子：问题带约束（例如 SVM：必须把样本分对且间隔至少为 1）时，把约束乘上系数 α_i 加进目标，变成无约束问题。 α_i 就是乘子，SVM 对偶里那些 α_i 就是它。

二次规划：目标是二次函数、约束是线性不等式。硬间隔 / 软间隔 SVM 都属于这类，交给成熟求解器即可。

凸优化：目标是凸函数时，局部最小就是全局最小。线性回归 MSE、对数几率回归的负对数似然是凸的；深层神经网络一般不是，所以会遇到局部极小/鞍点。

C. 常见分布与 KL 散度

分布	直觉	常见出场
均匀	一段里每个值机会相同	随机初始化、随机探索

分布	直觉	常见出场
伯努利	一次抛硬币，成功概率 p	二分类的每个样本
二项	抛 n 次硬币	计数
类别 / 多项	一次/多次掷骰子	多分类
高斯 / 正态	钟形曲线	噪声、GMM、很多先验
Beta	定义在 $(0, 1)$ 上，给「概率」本身建模	伯努利的共轭先验
狄利克雷	Beta 的多类版本	话题模型 LDA

共轭先验：先验和似然配对得巧妙时，后验和先验是同一类分布，更新参数特别方便。Beta-伯努利、狄利克雷-多项是最常见的一对。

KL 散度：

$$\text{KL}(p||q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$$

用 q 去近似 p 时的信息损失。 $p = q$ 时为 0；越大越不像。**不对称：** $\text{KL}(p||q) \neq \text{KL}(q||p)$ 。变分推断、VAE、知识蒸馏、对比学习里经常作为损失的一部分。

全书术语速查

按字母/主题，方便复习时跳回对应章。

术语	一句话	章
泛化	对新样本也准	1, 2
过拟合	训练集很好、新数据很差	2
验证集	调超参数用，不能当最终测试	2
交叉验证	轮流当测试，评估更稳	2
精确率 P	报为正的里面对多少	2
召回率 R	真正的正例抓住多少	2
F1	P 和 R 的调和平均	2
AUC	ROC 下面积，排序质量	2
偏差-方差	模型太简 vs 太敏感	2
对数几率回归	线性 + Sigmoid 做分类	3
信息增益	划分后熵降了多少	4
剪枝	砍掉过细的树，防过拟合	4
激活函数	神经元里的非线性	5

术语	一句话	章
BP	反向算梯度来改权重	5
支持向量	撑起最大间隔边界的那些样本	6
核函数	不显式升维就算高维相似度	6
先验 / 后验	看数据前 / 后的类别概率	7
朴素贝叶斯	特征条件独立的贝叶斯分类	7
EM	隐变量问题的两步迭代	7
Boosting	串行关注错分样本	8
Bagging	并行抽样再投票	8
k-means	轮流分配样本与更新中心	9
PCA	找方差最大的投影方向	10
kNN	看邻居投票	10
L1 正则	趋向稀疏，可当特征选择	11
PAC	以大概率近似学对	12
VC 维	模型族有多能打散样本	12
半监督	少标记 + 多未标记	13
HMM	隐状态序列生成观测序列	14
CRF	给定观测，直接建模标记序列	14
MDP	状态、动作、转移、奖赏	16
探索-利用	试新的 vs 用已知最好的	16
Q-learning	用 TD 误差更新动作价值	16

给深度学习零基础的衔接清单

把西瓜书读完（至少前 10 章）之后，学深度学习可按这条线对接：

1. **第 2 章** → 你会正确划分数据集、看 loss/准确率/AUC，而不是只看训练精度。
2. **第 3 章** → 你认识线性层、Sigmoid、Softmax、交叉熵（极大似然）。
3. **第 5 章** → 你认识多层网络和 BP，可以开始写第一个 MLP。
4. **第 6、11 章** → 你理解间隔、正则、稀疏，对应 weight decay、过拟合控制。
5. **第 8 章** → 你理解「多个模型为什么能更好」，对应 Dropout、集成、Bagging 思想。
6. **第 10 章** → 你会用 PCA 做可视化/预处理，理解嵌入和距离。
7. **第 16 章** → 若做 RL，先吃透 Q-learning 再看 DQN。

下一本常见衔接书是《深度学习》（花书）或动手学深度学习教程。那时你会发现：新术语很多，但「损失、泛化、梯度、正则、评估」仍然是西瓜书这套语言。

复习自测（每章 3 问）

- 第 1 章 什么是归纳偏好？NFL 定理对选算法意味着什么？监督和无监督的差别？
- 第 2 章 为什么不能用测试集调参？P 和 R 为什么此消彼长？偏差大是过拟合还是欠拟合？
- 第 3 章 对数几率回归为什么能做分类？OvR 和 OvO 差在哪？类别不平衡时精度有什么问题？
- 第 4 章 信息增益为什么偏好取值多的属性？预剪枝和后剪枝谁更不容易欠拟合？基尼指数衡量什么？
- 第 5 章 感知机为什么搞不定异或？BP 的前向和反向各在干什么？学习率太大/太小会怎样？
- 第 6 章 间隔大为什么往往更好？核函数解决什么问题？C 太大太小分别怎样？
- 第 7 章 后验、先验、似然各是什么？朴素在哪？EM 的 E 步 M 步分别干什么？
- 第 8 章 Boosting 和 Bagging 谁串行谁并行？随机森林比普通 Bagging 多了什么随机性？
- 第 9 章 k-means 的两个循环步骤？GMM 和 k-means 最大直观差别？DBSCAN 能发现什么形状？
- 第 10 章 PCA 选的是什么方向？kNN 的 k 过大过小？度量学习在学什么？
- 第 11 章 Filter / Wrapper / Embedded 差别？L1 和 L2 谁更容易得到 0 权重？
- 第 12 章 PAC 的两个词 Probably、Approximately 各指什么？VC 维高通常意味着什么？
- 第 13 章 未标记样本在什么假设下有用？协同训练的「互相打伪标签」是什么意思？
- 第 14 章 HMM 里什么隐、什么显？CRF 和 HMM 谁是判别式？
- 第 15 章 序贯覆盖在重复做什么？
- 第 16 章 探索与利用矛盾是什么？Q-learning 更新式子里 $\max_{a'} Q(s', a')$ 在干什么？

能不看笔记答出大意，这一章就过关了。